

```
## Warning in grepl(db, input): input string 43 is invalid in this locale
## Warning in grepl(db, input): input string 44 is invalid in this locale
## Warning in grepl(db, input): input string 45 is invalid in this locale
## Warning in grepl(db, input): input string 48 is invalid in this locale
## Warning in grepl(db, input): input string 53 is invalid in this locale
## Warning in grep("^\\\\bibliography.+", input, value = TRUE): input
string 43 is invalid in this locale
## Warning in grep("^\\\\bibliography.+", input, value = TRUE): input
string 44 is invalid in this locale
## Warning in grep("^\\\\bibliography.+", input, value = TRUE): input
string 45 is invalid in this locale
## Warning in grep("^\\\\bibliography.+", input, value = TRUE): input
string 48 is invalid in this locale
## Warning in grep("^\\\\bibliography.+", input, value = TRUE): input
string 53 is invalid in this locale
```

РОЗДІЛ 1

ОГЛЯД СТАНУ ПРОБЛЕМИ ТА ПОСТАНОВКА ЗАДАЧІ ДОСЛІДЖЕННЯ

1.1. Навчання та самонавчання штучних нейронних мереж

Здатність навчатися – основна властивість біологічного мозку, а оскільки штучна нейронна мережа в деякому сенсі моделює мозок, поняття «навчання» посідає щонайперше місце в теорії штучних нейронних мереж. Математичні проблеми, що пов'язані з навчанням, вивчають у напрямі загальної теорії штучних нейронних мереж, який дістав назву «нейроматематика» [51, 52]. Із точки зору нейроматематики, навчання тлумачать як завдання адаптувати параметри, а можливо, й архітектуру мережі, щоби, оптимізуючи прийнятий критерій якості, розв'язати поставлену задачу. Таке визначення є узвичаєним та неявно припускає, що нейроматематика ґрунтується на методах оптимізації та ідентифікації.

Звичайно припускають, що навчання має перманентний характер та з часом мережа покращує свої характеристики, постійно «наближаючись» до оптимального розв'язку поставленої задачі.

Тип та характер навчання обумовлені, насамперед, обсягом попередньої та поточної інформації про довкілля, в яке «занурили» мережу, а також критерієм якості (цільовою функцією), що характеризує рівень відповідності нейронної мережі до розв'язуваної нею задачі. Інформацію про довкілля здебільшого задають у вигляді навчальної вибірки образів або зразків, що їх оброблюючи мережа дістає відомості, необхідні для отримання шуканого розв'язку. Саме характер та обсяг цієї інформації визначають як тип навчання, так і конкретний метод.

З погляду математики, навчання нейронних мереж – це багатопараме-

трична задача нелінійного оптимування. Більшість методів навчання можна розділити на два класи: навчання з учителем (із заохоченням) та навчання без учителя (без заохочення, або самонавчання). Методи навчання з учителем застосовують у випадках, коли відома бажана реакція системи в кожному мить часу, себто відомий навчальний сигнал, який впливає на налаштування параметрів системи, що навчається. Рівень «навченості» системи формально визначають за значенням цільової функції, тобто за тим станом, якого має в результаті набути коректно навчена система.

Парадигму навчання «з учителем» схематично представлено на рис. 1.1

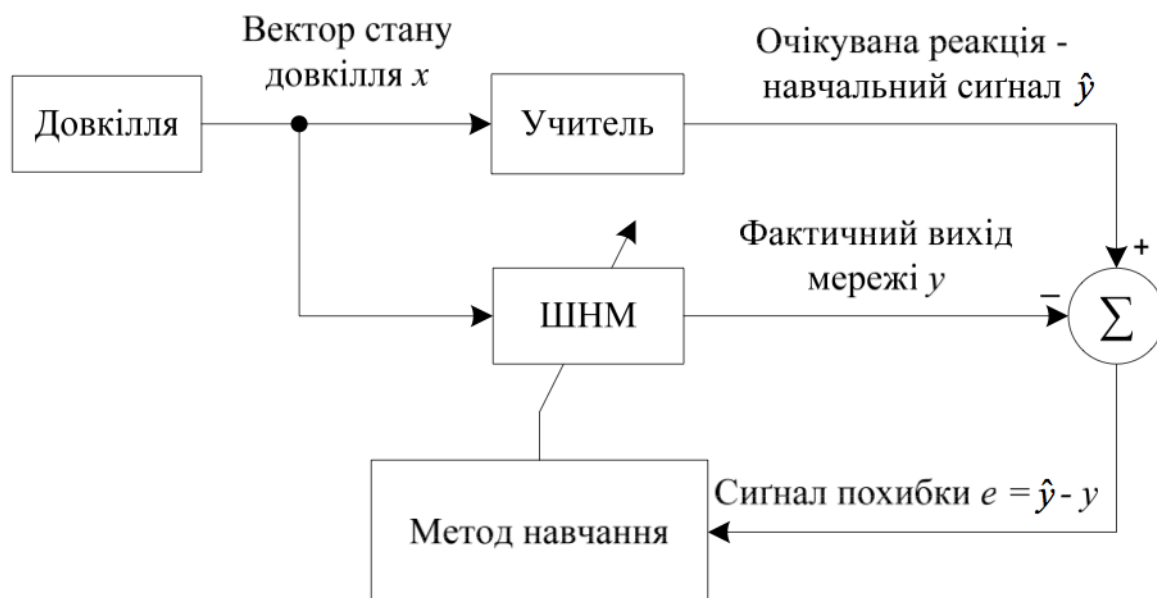


Рис. 1.1 – Схема навчання з учителем

У цій схемі «учителю» відома інформація про довкілля, представлена послідовністю або пакетом ухідних векторів x , а також «правильна реакція» на ці сигнали, позначена навчальним сигналом \hat{y} . В процесі навчання реакція нейронної мережі y розбігається з «правильною» реакцією вчителя, через що постає похибка $e = \hat{y} - y$. Мета навчання – так налаштувати параметри штучної нейронної мережі, щоби деяка скалярна функція похибки $E(e)$ (критерій якості) досягла свого найменшого значення. Навченою вважають мережу, яка в деякому, переважно статистичному сенсі повторює реакцію

вчителя. Позаяк інформація про довкілля здебільшого має нестационарний характер, навчання відбувається безперервно, для чого використовують ті чи інші рекурентні процедури.

Альтернатива навчанню «з учителем» – навчання за умов, коли правильна реакція на сигнали довкілля невідома. Цю парадигму називають навчанням «без учителя», або самонавчанням. Штучні нейронні мережі, що самонавчаються, здебільшого, призначені аналізувати внутрішню латентну структуру вхідної інформації та розв'язують задачі автоматичного класифікування, кластерування, факторного аналізу, компресування даних тощо. У теорії штучних нейронних мереж самонавчання звичайно розглядають як конкуренцію або самоорганізування нейронів мережі, що топологічно взаємозв'язані між собою.

Самонавчання схематично представлено на рис. 1.2.




Рис. 1.2 – Схема самонавчання

Аби покращити якість навчання та прискорити збіжність, ітераційне навчання можна повторювати циклічно на так званому «вікні» – наборі послідовних значень навчального сигналу (у дискретному випадку) або проміжкові часу (у неперервному випадку). Граничним варіантом процедур з повторюванням є пакетне та послідовне (у реальному часі) модифікування. Під пакетним режимом розуміють випадок, коли всю вибірку даних задано попередньо, а навчання відбувається «епохами». У режимі реального часу повторювання відсутнє, хоча якщо зорганізувати навчання в «прискореному»

машинному часі, навчання може повторюватися.

1.2. Задача нечіткого кластерування даних

Нечітке кластерування даних – один з напрямів кластерного аналізу, що використовує для оброблення даних деякі принципи та елементи нечіткої логіки [77, 78]. Концептуальний взаємозв'язок між кластерним аналізом та нечіткою логікою ґрунтується на тій обставині, що розв'язання задач структурування складних систем формує здебільшого кластери об'єктів, що є розмиті, нечіткі за своєю природою. Така нечіткість може полягати в тому, що перехід від належності до неналежності образів щодо певних кластерів радше поступовий, аніж стрибкуватий. Тому адекватнішою в таких випадках є не однозначна належність до певного кластеру, а низка рівнів належності до кількох кластерів. Вимога однозначно розкластерувати елементи досліджуваної проблемної області є вельми грубою та жорсткою, особливо у випадках, коли треба розв'язати погано або слабо структуровані задачі інтелектуального аналізу даних. Засоби нечіткого кластерування послаблюють цю вимогу введенням до розгляду нечітких кластерів та їхніх функцій належності, які приймають значення на інтервалі $[0, 1]$.

З-поміж цілої низки методів та підходів нечіткого кластерування особливе місце займають методи, що ґрунтуються на цільових функціях [79]. Такі методи розв'язують задачу оброблення даних, оптимуючи деякий заздалегідь заданий критерій якості. Найвідомішим представником цього класу методів є метод нечітких c -середніх [77], що його широко застосовують у задачах різноманітної складності, коли навчальний сигнал невідомий. Але хоча стандартний метод нечітких c -середніх є значно просунутішим порівняно з методами чіткого кластерування, але все ж таки й він має вади. Справа в тому, що однією з умов використання цього методу є вимога, щоби сума рівнів належності будь-якого образу за всіма кластерами дорівнювала одиниці. Ця штучна вимога у випадках рівновіддаленості деякого образу від усіх класте-

рів спричиняє те, що такий образ отримує рівень належності до кожного з кластерів, який не залежить од відстані між образом та центром відповідного кластеру. Іще однією вадою методу, яка впливає з попередньої, є припущення, що під час оброблення даних образи, що належать новим кластерам, з'явитися не можуть. Вочевидь, в реалістичних задачах це не завжди так. До того ж образи, що надходять на вхід методу, можуть бути звичайним шумом, завадами. Стандартний метод нечітких s -середніх не впорається з такою ситуацією, що відповідно позначиться на ефективності кінцевого нечіткого розбиття даних.

Зазначену ваду долає метод можливісного нечіткого кластерування даних – метод можливісних s -середніх [77, 80, 81]. Він не має вимог щодо значення суми рівнів належності образів за всіма кластерами, що, відповідно, покращує його дієвість за умов наявності шуму в ухідному сигналі. Проте цей метод має певні труднощі з його початковим ініціалізуванням.

Беручи до уваги те, що обидва розглянуті методи належать до методів нечіткого кластерування даних, тут годилося б зазначити, що коли виникає потреба виокремити стандартний метод нечітких s -середніх, його називають імовірнісним.

Два розглянуті методи нечіткого кластерування даних – імовірнісний та можливісний – є базові методи, які утворюють цілі сім'ї похідних від них і пристосованих до певних специфічних задач оброблення даних [77]. Зазвичай, кожен зі згаданих методів обробляє дані в пакетному режимі. У ситуаціях, коли дані надходять окремо й їх потрібно обробляти он-лайн, для методів нечіткого кластерування запропоновано послідовні модифікації [77, 82].

Іще одна вада стандартних методів нечіткого кластерування даних – нездатність виявляти кластери складної, несферичної форми. Цю ваду, окрім уже згаданого ієрархічного кластерування, долає метод нечіткого кластерування Густафсона-Кесселя, який, замість Евклідової, використовує Магаланобісову метрику [83].

Як видно, існує розмаїття методів нечіткого кластерування, зоснованих

на оптимуванні цільової функції. Але усі вони ґрунтуються на припущенні, що дослідникові попередньо відома кількість кластерів, що їх треба виявити. Дієвніше, таке припущення слушне не для всіх задач, адже інколи кількість кластерів у вхідних даних може бути невідомою або вона може змінюватися в часі. Цей випадок є предметом розгляду систем оброблення даних із мінливою (еволюційною) архітектурою [84], які здебільшого є гібридними системами з поліпшеними архітектурами, що поєднують декілька напрямків обчислювального інтелекту.

1.3. Гібридні системи обчислювального інтелекту

В обчислювальному інтелекті вельми поширеним є підхід створювати системи оброблення даних на основі кількох наукових напрямів. Як засвідчують теоретичні та практичні результати, таким гібридним системам властивий синергетичний ефект, тобто вони виявляють такі властивості, яких не мають системи, що їх утворюють [85]. Одним з яскравих прикладів гібридних систем обчислювального інтелекту є нейро-фазі системи, які поєднують у собі нейронні мережі другого покоління та нечіткі системи [9, 85]. Нейронна мережа може навчатися на вхідних та вихідних даних для визначення поведінки системи, але отримані знання будуть сховані в її синапсових вагах і їх не можна буде витлумачити. Однак, якщо виразити ваги нейронної мережі за допомогою нечітких правил, з'являється можливість подолати неінтерпретовність результатів роботи нейронної мережі. У такий спосіб нейрофазі системи дають змогу створювати системи оброблення інформації та отримують більш широке застосування. Розвиваючи гібридний підхід, запропоновано й просунутіші поєднання наукових напрямків, наприклад, теорії штучних нейронних мереж та індуктивного моделювання даних [86]. Ефективність кластерування даних залежить у великій мірі від якості обраної математичної моделі розв'язуваної або досліджуваної задачі. Як уже мовилося вище, однією з проблем кластерування даних є змінна кількість кластерів оброблюваних даних. Від-

повідно постає складна задача обрати належну математичну модель. Індуктивне моделювання має тут ефективний розв'язок: налаштовувати не лише параметри системи оброблення даних, але також і її структуру. Проекція такого підходу на штучні нейронні мережі веде до ідеї змінювати кількість нейронів в шарах мережі, що обробляє дані. Дієвість роботи побудованих за цим принципом систем [87, 88] засвідчує плідність гібридного підходу.

1.4. Гібридні нейро-фаззі системи та питання структурної адаптації

В наш час для розв'язання задач, які пов'язані з інтелектуальною обробкою даних в умовах апріорної та поточної невизначеності, дослідники часто не обмежуються використанням якогось одного підходу (нейронні мережі, нечітка логіка, генетичні алгоритми тощо), а задля синергії зв'язують групу методів в одну гібридну систему [? ?] . Такі системи відповідають усім вимогам до інтелектуальних систем і отримали назву гібридні системи обчислювального інтелекту. Нейро-фаззі системи та м'які обчислювання є напрямками дисципліни обчислювального інтелекту, які й займаються проблемами таких систем. Серед основних характеристик систем, що розробляються в рамках нейро-фаззі систем та м'яких обчислень, можна виділити наступні [27]:

- обчислювальні моделі, що засновані на біологічних прототипах,
- паралельна обробка даних у послідовному режимі,
- в основі системи лежать експертні знання,
- стійкість системи до зашумленості,
- стійкість системи до виходу із строю підсистем.

Варто зазначити, що однією із головних умов до такого типу систем, є їх орієнтованість на розв'язання практичних завдань, що означає здатність оброблювати великі масиви даних великої розмірності, які можуть мати пропущені та зашумлені значення. Однак навчання таких систем зводиться до налаштування синаптичних коефіцієнтів та/або адаптації бази нечітких пра-

вил. Тобто архітектура такої системи не зазнає жодних змін, що може в деяких випадках призвести до погіршення точності результатів. В зв'язку з цим видається очевидно корисним зсинтезувати таку гібридну нейро-фаззі архітектуру та такі алгоритми її навчання, що здатні змінювати не тільки параметри системи, а й її архітектуру.

Як вже зазначалось, основною метою навчання є отримання нейронної мережі, яка здатна у найкращий спосіб відтворювати попередньо невідоме відображення $R^n \rightarrow R^m$. В якості такого відображення може виступати залежність вихідних параметрів процесу від вхідних, прогнозування від передісторії, класу об'єкту від набору його властивостей, управляючої дії від поточного стану об'єкта тощо. Коректне налаштування не тільки синаптичних коефіцієнтів, а й архітектури нейронної мережі, зокрема налаштування кількості шарів та кількості нейронів у кожному шарі, дозволяю суттєво покращити показники такої мережі. Серед підходів до налаштування архітектури нейронної мережі виділяють:

- деструктивний підхід: за основу береться заздалегідь надлишкова модель, до неї застосовуються різні процедури, що видаляють із початкової мережі елементи, які надають негативний або незначний позитивний ефект на кінцевий результат,
- конструктивний підхід: за основу береться максимально проста модель (складається із одного або декількох нейронів), до неї застосовуються процедури, що додають початковій мережі нові елементи до певного моменту, в залежності від методу, що використовується. Як варіант, конструктивний алгоритм може стартувати з цілком нульової архітектури та самостійно генерувати шари мережі в процесі своєї роботи.

1.4.1. Деструктивний підхід до налаштування архітектури нейронної мережі. Основна ідея деструктивних алгоритмів полягає у видаленні параметрів, що мають найменший вплив на вихідний сигнал мережі. У

ряді публікацій [30-32] було сформульовано та підтвержено припущення, що використання деструктивних алгоритмів нерідко призводить до покращення узагальнюючих властивостей мережі, допомагає нейтралізувати появу так званого ефекту перенавчання, а, крім того, після закінчення роботи такого алгоритму, архітектура мережі набуває меншого та простішого вигляду, що, вочевидь, позитивно відбивається на її обчислювальній складності.

У процесі функціонування деструктивних алгоритмів із мережі можуть бути цілком видалені як деякі вхідні параметри або вузли у прихованих шарах, так і лише деякі синаптичні зв'язки між нейронами, що мають лише один параметр – ваговий коефіцієнт. В основі деструктивного піходу до структурної адаптації нейронної мережі має бути закладено обчислення певної міри значущості, яка буде характеризувати ступінь впливу кожного конкретного параметру на вихідний сигнал.

В одній із перших публікацій, що розглядає цю проблему [30], автори запропонували деструктивний алгоритм структурної оптимізації під назвою Optimal Brain Damage (OBD), який складається із наступних етапів:

1. обрати архітектуру нейронної мережі,
2. використовуючи один із методів мінімізації цільової функції якості, провести навчання мережі,
3. для кожного елемента мережі обчислити міру значущості за формулою:

$$s_q = h_q u_q^2 / 2, \quad (1.1)$$

де u_q – вихідний сигнал q -го елемента мережі,
 h_q розраховується по формулі:

$$h_q = \sum_{(i,j) \in V_q} \frac{\partial^2 E}{\partial w_{ij}^2}, \quad (1.2)$$

де V_q – множина пар коефіцієнтів i та j для q -го елемента мережі,
 E – помилка на виході нейронної мережі,
 w_{ij} – синаптичний ваговий коефіцієнт в j -м шарі,

4. видалити із мережі деяку кількість елементів, для яких міра значущості s_q найменша. У цьому контексті під видаленням елементу мається на увазі зміна вихідного значення елемента на 0 та замороження його в такому стані,
5. повернутися на крок 2 та повторити процедуру.

Варто зазначити, що при використанні такого методу значно збільшується обчислювальна складність методу навчання, і через необхідність розрахувати міру значущості для кожного нейрону, і через додаткові ітерації перенавчання, які необхідно виконати після видалення кожного нейрона із мережі. Також суттєвим недоліком є те, що разом з видаленням нейрона ми видаляємо відразу декілька синаптичних зв'язків, хоча деякі із них можуть бути корисними. У [31] було запропоновано спосіб обійти цей недолік, а разом із тим збільшити швидкість процесу навчання. Цей підхід отримав назву Optimal Brain Surgeon (OBS), і складається він із наступних етапів:

1. вибрати мережу із достатньо надлишковою архітектурою та провести її навчання,
2. обчислити H^{-1} - матрицю, зворотною до гессіану: $H = \frac{\partial^2 E}{\partial w^2}$,
3. обчислити міру значущості для кожного елемента:

$$L_q = w_q^2 / (2[H^{-1}]_{qq}), \quad (1.3)$$

де w_q – q -ий ваговий коефіцієнт в мережі,

4. якщо мінімальний S_q значно менший за поточну помилку, то w_q має бути видалений, після чого перейти до кроку номер 5, в іншому разі перейти до кроку номер 6,
5. оновити вектор вагових коефіцієнтів мережі, використовуючи наступний вираз:

$$\delta W = -\frac{w_q}{[H^{-1}]_{qq}} H^{-1} \zeta_q, \quad (1.4)$$

де ζ_q – орт-вектор у площині вагових коефіцієнтів мережі, який відповідає q -й синаптичній вазі,

6. усі незначущі вагові коефіцієнти видаляються, після чого бажано перенавчити мережу.

Слід зауважити, що перший же крок цього методу, а саме вибір критерію надмірності архітектури, може викликати багато запитань. В цілому ж, запропонований в [31] метод також характеризується значною обчислювальною складністю, хоч і меншою, в порівнянні з OBD, оскільки він не потребує перенавчання всієї мережі після видалення кожного вагового коефіцієнта. Але методам, що описані вище, притаманний ще один істотний недолік – необхідність мати вже навчену нейронну мережу до початку роботи алгоритму. Це обмеження вдалося обійти завдяки методу, що був запропонований у [36], де міра значущості для вагових коефіцієнтів визначається через тестову статистику T , спираючись на те, що ваговий коефіцієнт обнуляється у процесі навчання мережі:

$$T_{(w_q)} = \log \left(\frac{\left| \sum_{k=1}^N \left(w_q - \eta \left(\frac{\partial E}{\partial w_q} \right)_k \right) \right|}{\eta \sqrt{\sum_{k=1}^N \left(\left(\frac{\partial E}{\partial w_q} \right)_k - \left(\frac{\partial E}{\partial w_q} \right) \right)^2}} \right), \quad (1.5)$$

де N – кількість прикладів у виборці.

У рамках деструктивного підходу відомі також і багато інших методів оптимізації архітектури нейронної мережі [33-35,37-39], проте в силу специфіки цього підходу всім їм в тій чи іншій мірі властива додаткова обчислювальна складність, а також орієнтація на нейронні мережі з архітектурою типу багат шарового персептрону. Використання таких алгоритмів для налаштування інших архітектур, зокрема для нейро-фаззі систем, неможливо,

а розробка видається недоцільною, оскільки в будь-якому разі використання деструктивного алгоритму матиме прямий негативний вплив як на час навчання, так і на час функціонування мережі. Для систем, що розробляються в рамках напряду нейро-фаззі і м'яких обчислень, час є досить критичним параметром, оскільки ці системи орієнтуються на рішення практичних задач. У зв'язку з цим вельми привабливо виглядає використання конструктивного підходу для синтезу архітектури нейронної мережі, про що йтиметься далі.

1.4.2. Конструктивний підхід до налаштування архітектури нейронної мережі. Суть конструктивного підходу полягає в нарощуванні архітектури нейронної мережі і налаштування її вагових коефіцієнтів паралельно, доки не будуть задоволені вимоги критерію зупинки. Тобто цей підхід дозволяє не тільки уникнути перенавчання нейронної мережі, а й оптимізує структуру й архітектуру мережі на етапі навчання.

Таким чином, використовуючи конструктивний підхід, можна повністю вирішити питання про вибір початкової архітектури мережі: в загальному випадку вона повинна бути максимально простою, складатися з одного або декількох нейронів (залежить від методу). Слід зауважити, що, як правило, в результаті роботи конкретного конструктивного алгоритму на виході отримуємо нейронну мережу нетрадиційної архітектури.

В [40] Джон Платт описує нейронну мережу, що дістала назву Resource-Allocating Network (RAN), яка в процесі навчання додає в свою архітектуру нові обчислювальні елементи (штучні нейрони) кожен раз, коли до входу мережі подається новий навчальний приклад, який в RAN має двошарову архітектуру. Перший шар складається з нейронів, що відповідають за локальну область з простору вхідних сигналів. У випадку, коли вхідний сигнал віддається від області конкретного нейрона, то значення сигналу на його виході зменшуватиметься відповідно співвідношенню:

$$\begin{cases} x_j = \begin{cases} \left(1 - \left(\frac{z_j}{\chi w_j^2}\right)\right)^2, & \text{якщо } z_j < \chi w_j^2 \\ 0, & \text{у протилежному випадку} \end{cases} \\ z_j = \sum_i (c_{ij} - X_i)^2, \end{cases} \quad (1.6)$$

де X_i — i -ий вхід нейронної мережі,

c_{ij} — i -ий ваговий коефіцієнт j -го нейрона першого шару,

χ — параметр налаштування, який підбирається емпіричним шляхом.

Виходи першого шару x_j подаються на другий шар, який агрегує ці значення і генерує вихідний сигнал. Метою кожного синапсу другого шару є визначити, який вплив надає кожен нейрон першого шару на формування конкретного цільового вектора \vec{y} . Вихідним сигналом мережі \vec{y} є зважена сума виходів першого шару плюс незалежний вектор $\vec{\gamma}$, що містить постійні елементи:

$$\vec{y} = \sum_j \vec{w}^{[\circ]} x_j + \vec{\gamma}, \quad (1.7)$$

де $\vec{w}^{[\circ]}$ —вектор синаптичних ваг вихідного шару, або в скалярній формі:

$$y_i = \sum_j w_{ji}^{[\circ]} x_j + \gamma. \quad (1.8)$$

Також $\vec{\gamma}$ є виходом нейронної мережі у випадку, якщо не активувався жоден з нейронів першого шару. У певному сенсі вираз $\vec{w}_j^{[\circ]} x_j$ може розглядатися як певний адитивний елемент, який може бути використаний для того, щоб отримати бажаний вихідний сигнал. Навчання RAN починається з нульового стану, тобто в першому шарі не міститься жодного нейрона, а в другому кількість нейронів дорівнює розмірності завдання, проте, на цьому

етапі всі вони, за винятком зсуву γ , не мають вхідних параметрів. Після подачі на вхід першого навчального прикладу у вхідній шар додається перший нейрон, центр функції активації (1.6) якого встановлено наступним чином:

$$\vec{c}_i = \vec{X}, \quad (1.9)$$

де k – номер прикладу у виборці.

Вихідний сигнал першого шару автоматично передається на всі нейрони другого шару, а його лінійні синапси налаштовуються таким чином, щоб різниця між виходом мережі і навчальним сигналом була мінімальна:

$$\vec{w}_j^{[\circ]} = \vec{Y} - \vec{y}, \quad (1.10)$$

де \vec{Y} – бажаний вихід мережі.

Доданий нейрон реагуватиме на нові вхідні сигнали, якщо вони будуть перебувати в певному інтервалі, який визначаються відстанню між найближчим вектором і новим вхідним образом

$$w_i = \omega \left\| \vec{X} - \vec{c}_{nearest} \right\|, \quad (1.11)$$

де ω – параметр покриття, підібраний емпіричним шляхом. Чим більше значення цього параметра, тим на більшу кількість вхідних сигналів будуть реагувати вже існуючі нейрони першого шару.

У RAN використовуються дві умови для додавання нового нейрона в перший шар мережі. По-перше, це відбувається в тому випадку, якщо вхідний сигнал знаходиться далеко від вже існуючих центрів функцій активації нейронів першого шару:

$$\left\| \vec{X} - \vec{c}_{nearest} \right\| > \delta(t), \quad (1.12)$$

а також у випадку, коли із допомогою поточного набору елементів не вдається забезпечити необхідну точність вихідного сигналу:

$$\|\vec{Y} - \vec{y}(\vec{X})\| > \varepsilon, \quad (1.13)$$

де ε – необхідна точність вихідного сигналу.

Якщо при подачі на вхід нового вектора на виході мережі ми отримуємо помилку більшу, ніж ε , то у вхідний шар мережі додається новий нейрон з центрами активаційних функцій, налаштованими на поточний вхідний образ. Відстань $\delta(k)$ – динамічний параметр, який змінює своє значення протягом процесу навчання. Для його калькуляції використовується наступний вираз:

$$\delta(k) = \max(\delta_{\max} e^{-i/\tau}, \delta_{\min}), \quad (1.14)$$

де δ_{\max} , δ_{\min} , τ – параметри, що вибираються емпірично.

Якщо згідно умов (1.12) і (1.13) не потребується додавання нового нейрона у вхідний шар, то проводиться налаштування вагових коефіцієнтів вихідного шару. Для цього можуть використовуватися градієнтні методи мінімізації або ж метод найменших квадратів.

На перших етапах навчання в мережу переважно додаються нові елементи, проте через деякий час цей процес сповільнюється і замість додавання нових нейронів у вхідному шар відбувається налаштування синаптичних вагових коефіцієнтів вихідного шару. Такий порядок роботи конструктивного алгоритму стає можливим завдяки використанню двох умов додавання нового нейрона (1.12) та (1.13), забезпечує оптимальну складність моделі нейронної мережі поряд з хорошим рівнем узагальнюючих здібностей. У разі використання виключно (1.12) найбільш ймовірно, що це призведе до перенавчання, а в разі – (1.13) можуть бути пропущені деякі нейрони вхідного

шару, що вплине на точність вихідного сигналу мережі.

Серед недоліків запропонованого Джоном Платтом методу має сенс назвати досить велику кількість параметрів, що підбираються емпірично, від яких безпосередньо залежить якість роботи RAN.

Надалі підхід до конструктивної організації архітектури нейронної мережі, відомий в англomовній літературі під назвою Resource Allocation, породив безліч різних модифікацій, які спрямовані на оптимізацію швидкості навчання і точності вихідного сигналу при вирішенні певного кола завдань [41-44].

В рамках конструктивного підходу можна виділити такий напрямок, як каскадні нейронні мережі [45-50], найбільш характерним і ефективним представником яких є каскадно-кореляційний архітектура, запропонована Фальманом і Леб'єром в роботі [45]. Основна особливість мережі цього типу полягає в можливості додавання нових вузлів у процесі навчання. На рис. 1.3 наведена схема подібної мережі, що містить два каскади.

На початку процесу навчання формується стандартна одношарова структура з декількома входами і єдиним виходом, яка навчається за допомогою того чи іншого нелінійного методу навчання. Після проходження всієї навчальної вибірки $x(1), x(2), \dots, x(N)$ оцінюється точність апроксимації і в тому випадку, якщо помилка занадто велика, формується каскад з n_2 нейронів-кандидатів, паралельно підключених до входів мережі $1, x_1, x_2, \dots, x_n$ і виходу першого каскаду $o^{[1]}$. Нейрони-кандидати, як правило, відрізняються один від одного початковими значеннями синаптичних вагових коефіцієнтів $W^{[2]}(0)$, видом функцій активації та алгоритмами навчання. На наступному етапі проводиться навчання нейронів другого каскаду при «заморожених» синаптичних коефіцієнтах $W^{[1]}(N)$ першого каскаду. Серед n_2 нейронів-кандидатів вибирається один нейрон-переможець, параметр кореляції якого [46]

$$R_{[q]}^2 = \left| \sum_{k=1}^N \left(o_q^{[2]}(k) - \bar{o}_q^{[2]} \right) \left(e_q^{[2]}(k) - \bar{e}_q^{[2]} \right) \right|, \quad q = 1, 2, \dots, n_2 \quad (1.15)$$

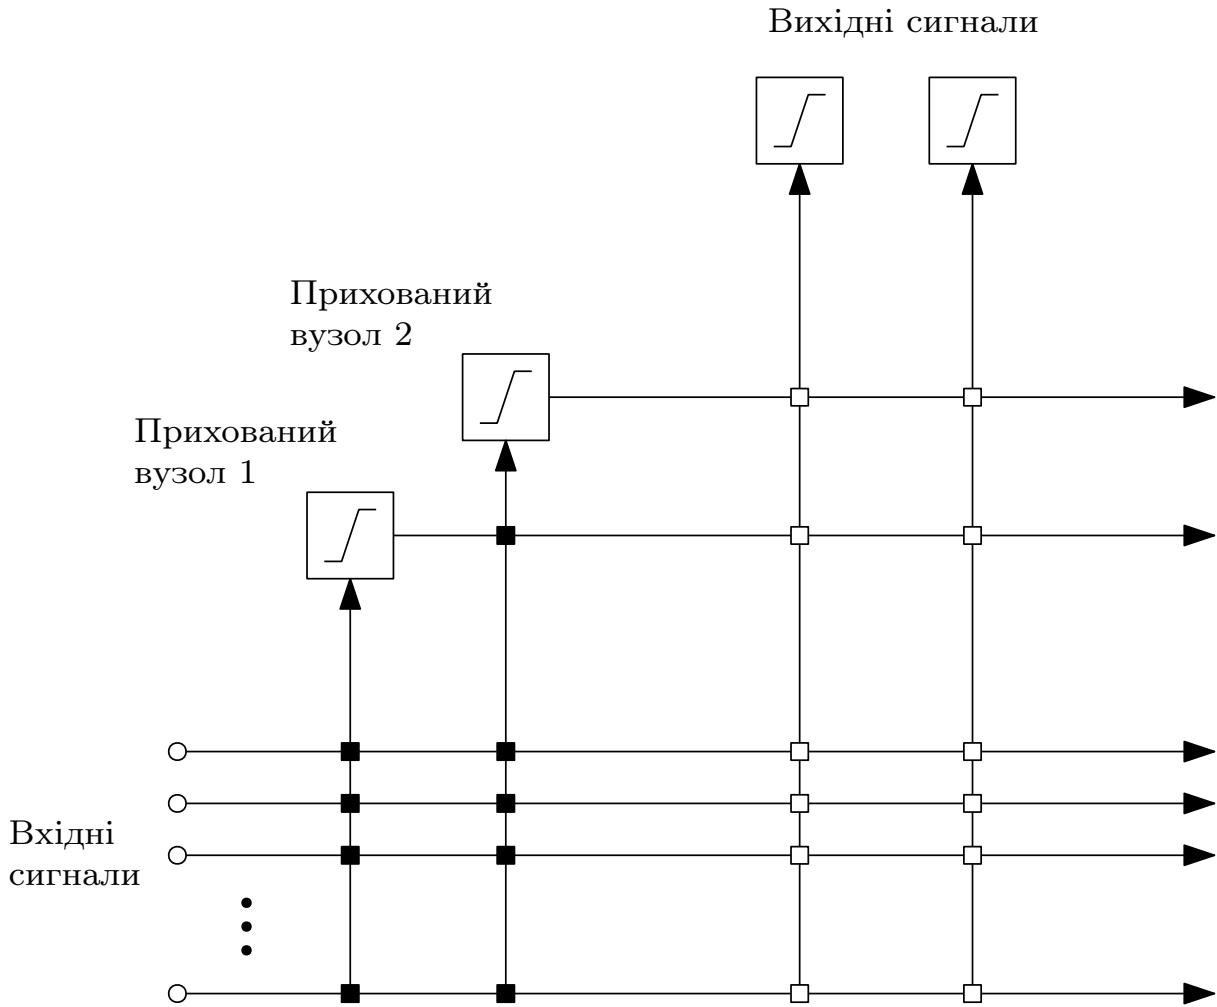


Рис. 1.3 – Архітектура каскадної системи (за Фальманом та Леб'єром) після додавання двох прихованих вузлів. Вхідні сигнали, що надходять до вертикальних ліній, сумуються; вагові коефіцієнти, позначені □, – зафіксовані, позначені ■, – налаштовуються

(тут $\bar{o}_q^{[2]}$ і $\bar{e}_q^{[2]}$ – середні значення вихідного сигналу і помилки) є максимальним. Саме цей нейрон з «замороженими» вагами $W^{[2]}(N)$ утворює другий каскад, в той час як нейрони, які програли, видаляються з мережі.

Далі оцінюється точність апроксимації, що забезпечується другим каскадом, і в разі потреби формується набір з n_3 кандидатів третього каскаду, серед яких вибирається переможець з максимальним значенням

$$R_{[q]}^3 = \left| \sum_{k=1}^N \left(o_q^{[3]}(k) - \bar{o}_q^{[3]} \right) \left(e_q^{[3]}(k) - \bar{e}_q^{[3]} \right) \right|, \quad q = 1, 2, \dots, n_3 \quad (1.16)$$

У разі досягнення необхідної точності процес нарощування каскадів завершу-

ється і вихідний сигнал останнього каскаду (на рис. 1.1 – $\bar{o}_q^{[3]}$) приймається в якості вихідного сигналу мережі в цілому. В якості основних відмінних рис каскадно-кореляційних мереж слід зазначити наступні:

- ці мережі не вимагають попереднього завдання ні архітектури, ні кількості нейронів в каскадах,
- нейрони в мережу додаються в міру необхідності, утворюючи не приховати шари, а каскади, кожен з яких в якості вхідних сигналів використовує входи мережі і виходи попереднього каскаду,
- навчання не пов'язане з концепцією зворотнього поширення помилок, що дозволяє істотно скоротити час налаштування
- за рахунок «заморожування» синаптичних ваг сформованих раніше каскадів скорочуються обчислювальні витрати на навчання.

Головним недоліком даних мереж прийнято вважати неможливість їх навчання в режимі послідовної обробки інформації [51]. Далі буде показано, як можна подолати це обмеження, синтезувавши на основі мережі, запропонованої в [45], архітектуру, яка буде відповідати критеріям, які висуваються до нейро-фаззі систем.

1.5. Постановка завдання дослідження

Оскільки сучасні обчислювальні технології дозволяють накопичувати і обробляти досить великі масиви інформації, то на перший план виходить швидкість оброблення даних, а також можливість роботи з ними в послідовному режимі. Крім того варто зазначити, що інформація, яка обробляється, може характеризуватися нелінійним і нестационарним характером даних. У таких випадках доцільно використання штучних нейронних мереж, які володіють універсальними апроксимуючими властивостями. Застосування апарату нечіткої логіки дозволяє розширити функціональні можливості штучних нейронних мереж і коло вирішуваних завдань. Завдання дослідження полягає в розробці архітектур нейро-фаззі мереж і методів їх навчання, що володіють

високою гнучкістю налаштування параметрів для інтелектуального аналізу даних в умовах невизначеності. Для досягнення поставленої мети необхідно розглянути наступні питання:

1. Аналіз існуючих нейро-фаззі архітектур і методів їх навчання.
2. Розробка спеціалізованих штучних нейронів, які мають підвищену (порівняно з традиційними нейронами) швидкістю навчання, а також здатних ефективно вирішувати завдання прогнозування, ідентифікації і класифікування в умовах апіорної і поточної невизначеності.
3. Розробка на основі цих нейронів штучних нейронних мереж зі зростаючою архітектурою та методів їх навчання.
4. Дослідження методів і способів, що дозволяють виконати гібридизацію (перехід від нейро до нейро-нечіткої системи).
5. Розробка методів навчання, що дозволяють гібридній нейро-нечіткій зростаючій архітектурі функціонувати в режимі послідовного оброблення інформації.
6. Проведення імітаційного моделювання розроблених методів і архітектур та розв'язання з їх допомогою практичних завдань.

Висновки до розділу 1

1. Розглянуто гібридні нейро-фаззі системи для вирішення завдань оброблення інформації за умови апіорної і поточної невизначеності. У якості головного недоліку таких систем виділено відсутність ефективних способів настройки архітектури з можливістю функціонувати в режимі реального часу.
2. Проаналізовано стан проблеми кластерування даних і розглянуті існуючі підходи до її вирішення. Розглянуто основні принципи нечіткої логіки та систем нечіткого висновування. Проаналізовані існуючі архітектури штучних нейронних мереж і методи їх самонавчання, що використовуються для вирішення завдань кластерування даних.

3. Проведено аналіз існуючих конструктивних і деструктивних методів структурної адаптації нейронних мереж. Виділено їх сильні і слабкі сторони. Обґрунтовано доцільність використання конструктивних алгоритмів для синтезу систем, що мають функціонувати в режимі послідовного оброблення даних.
4. Сформульовано завдання дослідження.

СПИСОК ВИКОРИСТАНИХ ДЖЕРЕЛ